

个人简历

细心从每一个小细节开始。

Personal resume



基本信息

姓 名：赵辉

工作年限：6 年

民 族：汉

年 龄：30 岁

电 话：15630125033

学 历：本科

邮箱：hughzhao2333@gmail.com

技能特长

精通大模型全链路开发，涵盖预训练、微调、强化学习对齐（RLHF/DPO）。具备分布式训练与推理优化能力，熟练运用PyTorch、DeepSpeed等框架解决性能与稳定性问题。擅长数据构建、预处理、大数据分析、提示词prompt工程，并能通过模型压缩（量化、剪枝）及vLLM/TGI等工具实现高效部署，推理性能优化，推动技术落地。负责过模型开发项目，agent开发，如：智能问答、智能问数等项目。包括基于RAG架构的内部知识库问答系统，以及将chatbi、nl2sql的数据查询平台，大模型应用平台开发等，均成功落地并显著提升了业务效率。

编程与工具：Python、SQL、Linux、Git、Docker

深度学习：PyTorch、Transformers、PEFT、MindSpore/mindformers、DeepSpeed、vLLM

LLM 与微调：Transformer/GLM/BERT/LLaMA；LoRA/QLoRA、Prefix-Tuning；RMSNorm、RoPE

推理与优化：FlashAttention、PagedAttention、KV Cache、并行/分布式训练（DDP/FSDP）

RAG 与 Agent：文本分片、索引构建、向量召回与重排（Rerank）、检索/答案评估、SQL/工具型

工作经历

2023-07 ~ 现在	北京致远互联软件股份有限公司	算法工程师
2022-06 ~ 2023-07	外企德科服务有限公司	算法工程师
2019-06 ~ 2022-05	北京和利时工业软件有限公司	算法工程师

一、智能问答系统

项目描述项：

搭建面向内部知识库的问答系统，覆盖规章制度/产品手册/流程文档等；采用检索增强生成（RAG）+ 工具调度 Agent（检索/SQL/日程等）以提升准确率与可追溯性，支持网页与 IM 端接入。

个人职责：

1. 设计分层检索：语义召回（bge/GTE 等）+ BM25 混合检索 + Rerank（bge-reranker/Cohere/Jina），优化切片（段落/标题/表格）与索引。
2. 构建 LangGraph 工作流（检索 → 证据聚合 → 答案生成 → 引用归因）；实现出处引用与段落高亮。
3. 部署 vLLM + KV Cache，结合 多路并发 + 请求批处理 提升吞吐；落地限流/熔断/重试与提示词模板化。
4. 建立评测集（黄金问答、难例/越权样例），指标：命中率、覆盖率、事实性（Faithfulness）、延迟/TP99
5. 加固安全：提示注入检测、域内越权拦截（Context Filter）、答案脱敏。

技术栈：

PyTorch、Transformers、vLLM/TGI、LangChain/LangGraph、FAISS/Milvus、bge-m3/GTE、bge-reranker、FastAPI、Redis、Prometheus/Grafana。

二、公文纠错

项目描述项：

1. 面向政企公文的自动化纠错与规范校对平台，涵盖术语/格式/标点/句法/敏感信息等；结合规则引擎 + LLM 校对的混合范式，产出可追踪的修改建议与依据条款。

个人职责：

2. 管线设计：PDF 解析（pdfplumber）、版面还原、段落/表格/页眉脚抽取；命名实体与术语库维护（同/异形词）。
3. 构建规则检查器（页边距/标点/日期/单位/数字大小写/用语套话等）+ LLM 生成式纠错（对齐风格/清晰度），并做冲突裁决。
4. 训练数据构造：从真实文档抽取“错-改”对，合成扰动样本（时态/助词/介词/易混词）。
5. 线上灰度：按文种配置规则权重；支持批量报告与逐条比对（Diff/高亮/参考条款）

技术栈：

Python、FastAPI、pdfplumber、Transformers + PEFT（LoRA/QLoRA）、PostgreSQL/Elasticsearch

三.智能问数

项目描述项：

智能问数系统，自动选择数据库与表/字段，生成可执行 SQL 并出图表，适配权限与行列级脱敏。

个人职责：

- 1.语义到结构映射：库/表/字段语义对齐，构建 Schema Linking & 候选列集；ReAct/Toolformer 风格的 SQL 工具使用。

2.质量保障: SQLGlot/SQLite 沙箱校验, 死锁/全表扫/慢 SQL 规避; Top-K 候选 SQL rerank + 回答置信度

3.可视化: 自动图表建议(柱/折/饼/分箱), 导出到 BI;

技术栈:

LangChain/LangGraph、AutoGen、SQLGlot、MySQL/ClickHouse、Transformers + 指令微调(Text2SQL 任务)、vLLM、FastAPI、Redis。

四、煤矿安全生产知识大脑

项目描述项:

围绕安全生产条例、案例报告、隐患排查清单构建的行业知识大模型应用; 提供法规检索、隐患问答、情境化 SOP 生成与整改单模板化输出。

个人职责:

1. 行业本体与术语库沉淀; 构建法规-措施-场景三元关系, 提升检索可解释性。
2. RAG 流程: 法规片段召回 + 证据对齐 + 风险提示; 针对高风险诱导设计拒答策略。
3. 评测: 法规命中率、引用正确率、行业术语一致性; 冷启动 & 增量更新。

技术栈:

FAISS/Milvus、bge/GTE + reranker、LangChain/LangGraph、FastAPI、vLLM、Neo4j

五、财务公司贷前信息审核系统

项目描述项:

对贷前材料(营业执照、流水、合同、票据)做结构化抽取与一致性校验; 结合 LLM + 规则引擎产出红/黄旗提示与合规解释。

个人职责:

1. OCR/版面理解 → 关键信息抽取(公司名/税号/金额/日期/机构); 跨文档一致性比对。
2. 风险规则: 拉黑名单、异常金额/日期、不一致字段; 可解释原因链路(来源页码/文本)。
3. 服务治理: 队列化处理、断点续传、失败重试; 报表导出与审计留痕。

技术栈:

PaddleOCR、Transformers、规则引擎、FastAPI、PostgreSQL、Redis

六、竹间智能大模型

项目描述项:

对接通用/中文对话大模型(如 Qwen/GLM/Llama 系列)到企业场景; 实现多轮对话管理、工具使用、记忆与安全策略。

个人职责:

1. 模型选型 & 参数/量化策略(AWQ/INT4); 构建函数调用与工具链(检索/SQL/日程/翻译)
2. 提示词工程: 系统提示/风格/少样本模版化; 越权与注入安全对策。
3. 观测: 对话 Win-Rate/人工红蓝评审、对话失败归因、提示词 A/B。

技术栈:

vLLM/TGI、LangChain/函数调用、PEFT (LoRA/QLoRA)、FastAPI、Redis、Prometheus、Langfuse。

七、企业级 Agent 平台化

项目描述项：

将分散的问答/问数/公文/检索能力统一到Agent 平台，以 LangGraph 编排节点（意图识别 → 工具选择 → 生成/校对 → 引用/审计），支持灰度发布与多租户隔离。。

个人职责：

1. 设计 Router → Planner → Tool Executor → Answerer 的子图；通过消息总线实现跨服务编排
2. 引入Guardrails (Pydantic/JSON Schema) 与内容安全（地理/权限/标签）并打通审计流水。
3. 成果：统一接口、统一观测、统一权限；缩短新业务集成周期。

技术栈：

LangGraph/AutoGen 或 CrewAI、FastAPI、Redis、Kafka（可选）、vLLM、Milvus/pgvector、Langfuse、Prometheus/Grafana。

技能证书

华为高级认证HCIP-AI证书

华为人工智能HCCDP-AI证书

华为人工智能HCCDP-iot证书

教育背景

河北科技大学 本科 理工学院

- 在校期间为AI实验室NLP小组组长
- 多次获得校内奖学金
- AI研习社社员

自我评价

- 有良好的代码习惯，习惯添加关键注释
- 善于沟通交流,具有良好的沟通协作能力,懂得团队协作的重要性
- 对工作认真积极，责任心强，做事言行严谨一致
- 较强的数理分析、逻辑推理和再学习能力
- 对新鲜事物充满兴趣，并能较快接受并掌握
- 对处理未知、挑战性问题充满激情，善于通过编辑代码验证自己的一些想法

