

宋怀杰

性别：男

年龄：26

电话：17703205109

邮箱：17703205109@163.com



教育经历

2017.09 - 2021.07

河北工程大学科信学院

计算机科学与技术（应用技术） | 本科

工作经历

2023.01 - 至今

上海新励信息科技有限公司

NLP算法工程师

工作内容：

- 参与 MCP 架构设计与开发，实现模块化的工作流管理。
- 基于 RAG 技术，显著提升垂直领域性能表现。
- 大语言模型的部署与微调，结合领域数据进行效果优化。
- 利用 Dify 框架构建智能对话系统，从需求分析、模型接入到生产部署。
- 数字人项目开发，完成从技术调研到核心模块实现。

2021.07 - 2022.12

上海奥腾计算机科技有限公司

算法工程师

工作内容：

参与自然语言处理算法（传统机器学习方法和深度学习）的设计及产品研发

- 实体抽取、关系抽取和情感分析等
- 自然语言理解核心算法研究
- 知识图谱、文本语义表示和深度语义匹配等
- 自然语言生成核心算法研究
- 语言模型、语句生成和语句规划等
- 自动问答和领域对话等语义交互产品研发，语言模型、语句生成和语句规划等
- 自动问答和领域对话等语义交互产品研发

项目经历

2025.04 - 至今

新励智能运营

项目背景：

本项目旨在开发一套基于大语言模型与 MCP 协议的企业多部门智能自动化平台，通过自研的服务发现与智能调度机制，实现人力资源、销售、财务等核心业务流程的自动化处理。平台支持多服务自动注册与按需启动，结合大模型的语义理解能力与后端工具的专业处理能力，显著提升企业运营效率，降低人力成本，满足企业对高效、智能办公的需求。

项目流程：

- 1：梳理人力资源、销售、财务等部门的日常业务，提取可自动化的核心任务，明确各模块的输入输出。
- 2：基于MCP 协议的服务注册与发现机制，实现客户端自动扫描。
- 3：注册后端各部门服务，支持多服务按需启动与资源自动回收。
- 4：实现部门模块相关工具，实现自动化流程。
- 5：集成 deepseek-v3 等国产大模型，优化多轮工具调用和长文本处理，提升系统响应速度与准确率。
- 6：通过人工评估和专业指标对系统进行测试与优化，最终完成平台部署，满足企业实际应用需求。

2024.10 - 2025.04

小励数字人

项目背景：

为满足用户对高效、精准中医咨询的需求，开发了一个基于AI的中医问答数字人系统，通过语音交互、自然语言处理和数字人技术，提供智能化的中医问答服务。

项目流程：

- 1：实现语音唤醒功能，确保用户可以通过语音指令唤醒数字人。
- 2：使用语音降噪技术处理用户输入的语音，提升语音识别效果。
- 3：集成语音识别（ASR）技术，将用户语音转换为文本。
- 4：使用Dify平台和Deepseek-r1模型，处理用户的中医相关问题。
- 5：实现语音合成（TTS）功能，将系统回复转换为专家音色的语音。
- 6：开发图片数字人功能，使静态图片能够根据语音内容张嘴说话。
- 7：实现视频数字人功能，驱动视频中的人物口型与语音同步。
- 8：开发前端页面，展示数字人形象并提供用户交互界面。
- 9：基于WebSocket实现中控调度系统，确保用户与数字人的实时对话。

2024.05 - 2024.10

新励智能检索

项目背景：

在医疗科学高速发展的时代背景下，医学知识体系呈现指数级增长态势，传统的信息检索方式及问答机制难以有效应对精准化医疗场景的多样化需求。为破解这一行业痛点，本研究拟采用知识增强生成技术框架，整合前沿语言模型、多模态语义理解及智能检索系统，构建具备深度语义理解能力的医疗知识服务平台。该平台着力解决非结构化医学资料的高效解析、跨模态医疗数据的智能处理以及专业级知识服务精准输出三大核心问题，为医疗工作者和科研人员提供即时可靠的决策支持。

项目流程：

- 1：完成行业主流知识增强技术方案的对比分析，确立融合语义检索与生成优化的混合架构。
- 2：实施PDF的智能解析，构建包含表格重构、图像OCR识别和文本纠错的预处理流水线。
- 3：开发基于大模型的语义清洗工具，实现非结构化数据的规范化转换。
- 4：设计动态分块算法，结合上下文感知的提示工程实现知识单元的智能切分。
- 5：采用BGE语义编码器完成特征向量化，搭建FAISS向量化存储引擎。
- 6：构建Redis驱动的对话状态管理，实现指代消解与上下文关联。
- 7：开发查询扩展引擎，集成语义改写与同义词增强技术。

- 8：设计多阶段检索优化流程，包含候选集重排序算法和可信度评分机制。
- 9：实现知识增强的生成控制器，平衡事实准确性与语义连贯性。
- 10：构建自动化问答对生成平台，产出领域适配的微调数据集。
- 11：开展检索器与生成模型的联合优化训练。
- 12：部署RAGAS评估矩阵，建立多维度的效果监测体系。

2023.12 - 2024.05

小励chatflow

项目背景：

人工智能技术正在革新医疗领域。中医虽独具"辨证论治"特色，但理论抽象和经验传承问题制约其推广。通过AI中医诊疗机器人，可实现智能问诊、辅助诊断和个性调养三大功能建议，既保持中医精髓，又突破传统局限，以推动中医文化的普及与应用。

项目流程：

- 1：人工筛选核心诊疗理论，使用Python工具完成文本格式标准化与冗余信息清理。
- 2：根据中医辨证论治体系，将症状、脉象、舌象等临床要素建立关联关系，组建中医专家团队完成数据标注与逻辑核验。
- 3：基于诊疗逻辑构建多层级知识框架，将清洗后的中医理论转化为可调用的数字化知识单元。
- 4：在Dify平台设计诊疗工作流，实现用户症状输入、知识库检索匹配、中医辨证分析及调理方案输出的完整链路。

2023.06 - 2023.12

新励智能智库

项目描述：

基于langchain的强大功能以及llm的迅速发展，公司希望可以构建自己的一个本地知识库，将公司大量文献资料上传到知识库中，能够实现一个知识的快速检索和资料整理。

项目流程：

- 1：连接训练好的chatglm2-6B大语言模型。
- 2：将知识文本传入到langchain中进行文本加载，文本分割，和文本向量化储存。
- 3：将query传入到langchain中，进行文本加载及向量化处理。
- 4：利用faiss将query向量和向量库中储存的知识进行相似度计算，匹配出最相似的几条文本，构造对应的prompt模板。
- 5：将prompt传入到llm模型中，生成相应的回答。

2023.01 - 2023.06

新励大模型

项目描述：

随着 ChatGPT 的发布，大模型在行业内越来越火热，将来肯定是大模型的时代，国内外巨头纷纷入局，我们公司也开发了自己的大语言模型，用来解决公司闲聊业务模块出现的问题，通过自动化评价系统代替人工评价，从海量数据中挑选出优质的对话语料，构建自己的数据库。

项目流程：

一：大模型训练

- 1：对大量的开源数据进行清洗。
- 2：使用 GLM 框架训练 GLM-6B 模型。
- 3：使用有监督语料继续进行学习。
- 4：进行基于人类反馈的强化学习，对一个问题生成的 4 个回复，进行从好到快的排序。
- 5：使用 PPO 策略进行模型训练，以及参数的优化。

二：自动化评价系统

- 1：针对不同的维度分别进行建模，维度选择：连贯性，信息量，流利性，是否符合事实。
- 2：得到不同维度的分数，取加权平均分。

2022.05 - 2022.12

电子病历生成

项目背景：

当前医疗机构依赖人工记录医患问诊内容，存在记录效率低、信息标准化程度不足及关键临床要素易缺失等问题，影响后续诊疗决策与病历管理。为解决这一痛点，本研究聚焦医患对话的自动化解析与结构化处理，通过音频转录、文本语义分析及时序推理技术，将非结构化问诊内容转化为包含主诉、现病史、既往史等标准化模块的电子病历，实现临床信息的高精度提取与规范化存储，为医疗数据的高效利用提供技术支撑。

项目流程：

- 1：构建医疗对话语料库，通过音频降噪与文本正则化处理医患交流数据（来源包含脱敏门诊录音及公开问诊文本）。
- 2：实施病历要素标注工程，完成医学关键词标记（症状表现/持续周期/用药情况）和问诊段落标注（主诉内容/病史详情/既往情况）。
- 3：研发医疗文本解析模型，运用序列标注技术提取医学实体，采用文本分类方法识别段落功能，开发时间关系解析模块构建诊疗时序。
- 4：定义电子病历内容框架，规范主诉描述模板、病史发展时序表、既往情况记录表三大核心模块。
- 5：构建医疗领域模型优化方案，采用专业术语强化训练和临床文档模式迁移实现领域适应。
- 6：开发问诊记录转换系统，实现语音文本双模式输入处理，构建包含语音识别模块和病历预览界面的处理流程。
- 7：执行系统效果验证，通过实体识别准确率、段落分类召回率及处理延迟指标进行性能调优。
- 8：实现医疗系统对接，开发标准病历导出接口完成与医院信息管理平台的整合。
- 9：建立系统迭代机制，通过医生评价收集和错误样本回传实现持续改进。

2021.12 - 2022.05

奥腾ai医生

项目描述：

随着疫情的蔓延，大量人员被困在家中，导致医疗需求激增。为满足市场需求，我们研发了一款基于知识图谱的智能医疗助手，它通过对话与患者交流，收集症状信息，并将这些信息提供给医生，以帮助患者解决医疗问题。

项目流程：

一：线下部分

- 1：梳理业务线，构建知识库的关系结构（Schema）。
- 2：清洗结构化和非结构化数据，完成数据准备。
- 3：使用Bert + Bilstm + CRF进行疾病和症状的实体识别。
- 4：利用Bert + RNN进行知识融合，确保数据符合医学命名规范。
- 5：使用Simcse计算语义相似度，以确定相似疾病，进行知识融合。
- 6：数据存储至Neo4j数据库。

二：线上部分

- 1：搭建Werobot服务，实现用户信息传递至后台。
- 2：使用Bert + Fine-tune + 线性层对用户意图进行一致性判断。
- 3：利用GPT2搭建业务中的闲聊模块。
- 4：构建主逻辑服务模块，支持多轮对话服务。
- 5：对于首次访问用户，使用AC自动机识别输入中的症状实体，使用实体链接查询，并将结果存入Redis数

- 数据库。
- 6：对于非首次访问用户，通过主题相关模型判断上一轮对话与当前对话的意图一致性，以区分是闲聊还是再次查询疾病。
- 7：使用Flask、Nginx和Supervisor进行项目部署。

2021.07 - 2021.12

奥腾病患机器人

项目描述：

为了缓解医院的压力，我们给医院做了医疗问答机器人，可以使用该机器人提前回答患者的各种问题，减小医生的压力，并且丰富医院的HIS库。

- 项目流程：
- 一：医疗知识图谱的构建
- 1：构建本体Schema框架，确定高层本体。
- 2：针对用户问题梳理业务线，确定底层本体。
- 3：根据本体确定关系，属性。
- 4：收集数据并进行处理，实例化本体，人工审核后存入Neo4j数据库中。
- 5：对医疗知识图谱进行评估。
- 二：医疗问答
- 1：搭建TinyBert+RNN结合模板匹配进行六类意图识别。
- 2：搭建TinyBert+GRU结合模板匹配进行十类意图识别。
- 3：根据主意图的结果触发副意图，查询知识图谱，结果以模板的形式返回给用户。
- 4：使用 Flask封装服务部署。

相关技能

- 熟练应用RAG以及变体GraphRAG知识图谱增强与LightRAG轻量化检索技术构建智能问答系统
- 熟练微调与部署Qwen、GLM、LLaMA等大语言模型，实现领域场景适配及高并发服务（vLLM/xinference）
- 熟练设计动态Prompt工程策略（结构化模板/多专家路由），提升大模型指令遵循准确率
- 熟练部署Qwen-VL多模态模型，开发图文跨模态语义对齐与联合推理系统
- 熟练基于Dify框架搭建Workflow自动化流程，优化Chatflow多轮对话交互逻辑
- 熟练开发传统机器学习模型（XGBoost/SVM/K-means），结合特征工程优化业务指标
- 熟练实现Word2Vec、BERT、LSTM等深度模型，解决文本分类与序列预测任务（Pytorch/TensorFlow）
- 熟练应用sglang推理加速与vLLM高并发框架，支撑千级QPS场景下的低延迟响应
- 熟练构建Milvus、Faiss多级向量索引，实现亿级数据毫秒级相似性检索
- 熟练开发MySQL关系型数据库与Neo4j知识图谱系统，设计Redis缓存策略优化实时查询
- 熟练使用Python实现模型训练Pipeline，结合Docker容器化部署与Linux运维保障系统稳定性

自我评价

- 1.性格方面属于沉着、稳重型。对待工作态度认真严谨，有较强的责任心，能够吃苦耐劳，且善于学习。
- 2.待人方面随和，喜欢结交朋友，有较强的新环境适应能力，擅长与人交流。
- 3.处事方面，习惯于有计划行事，擅长管理自己的时间。
- 4.对待自己的错误能有正确的认识，坚信从错误中总结经验能让自己获得提高。

