

辛九辰

电话: 177-3413-3562

学历: 统招本科

邮箱: 17734133562@163.com

学校: 潍坊学院

年龄: 25

专业技能

- 具备多 Agent 架构设计与落地经验, 熟悉 A2A 通信协议与 MCP 控制机制, 能够实现任务调度、状态管理与协同决策;
- 熟悉 LangChain 等原生 Agent 框架, 支持自主规划、工具调用与多步推理, 可构建目标驱动的智能体系;
- 熟悉 Dify 等低代码平台, 可用于快速实现 RAG 与流程自动化类应用的原型验证, 支持从 PoC 到生产的平滑演进;
- 掌握 vLLM、PagedAttention 等推理加速技术, 具备高并发、低延迟推理服务的优化能力;
- 掌握 LoRA、Prefix-Tuning 等参数高效微调方法, 能够基于 PEFT 框架完成模型轻量化部署;
- 深入理解 RAG 架构与混合检索机制, 熟悉向量数据库与结构化数据融合的检索策略;
- 深入理解 Transformer (BERT、GPT系列) 与 LSTM 等时序模型的应用场景;
- 具备非结构化数据处理与特征工程能力, 熟练使用 Python、pandas、NumPy 进行数据清洗与建模。

工作经验

明城智慧科技有限公司

大模型算法工程师

2023.10-至今

工作职责:

- 负责 RAG 智能运维系统与多 Agent 架构研发, 实现从故障诊断到预测性维护的升级。
- 推动大模型推理优化与微调, 提升诊断准确率并显著降低调用成本。

馨悦科技有限公司

大模型算法工程师 (实习)

2022.09-2023.10

工作职责:

- 参与设备故障诊断系统研发, 基于日志与传感器数据构建文本分类模型, 实现早期故障预测。
- 优化模型迭代并完成轻量化部署, 提升准确率与推理效率。

项目经历

车间小助手(二期)

2025.05 - 2025.09

项目背景:

第一期主要解决“故障后诊断”, 缺乏主动预防能力。第二期引入 多 Agent 协同架构, 实现了“从被动响应到主动预测”的演进。

技术栈: LangGraph, Qwen-Agent, MCP, LSTM-Attention

技术方案:

1, 多 Agent 协同工作流设计

基于 Qwen-Agent 与 MCP 协议, 设计 Orchestrator Agent 调度机制, 整合五类 Agent, 实现从报警接收到预测执行的闭环流程。

2, 推理优化

通过 LangGraph + vLLM 构建异步推理引擎, 实现多 Agent 并行处理, 推理吞吐量提升约 3.5 倍, 平均延迟降低至 120ms 以内。

3, 构建预测性维护能力

利用 LSTM + Attention 模型建模 12 个月设备时序数据, 实现故障 24-72 小时提前预警, 预测准确率 87.3%。

4, 搭建智能反馈闭环机制

工单执行结果自动写入知识库, 动态优化预测模型, 形成自进化能力, 预测性维护覆盖率提升至 62%。

项目成果:

新员工独立处理率从 35% 提升到 75%, 整体运维效率大幅提高, 平均停机时间缩短近 70%, 设备利用率显著提升;

车间小助手(一期)

2024.05 - 2025.04

项目背景:

传统设备运维依赖老师傅经验, 故障定位慢、知识分散。为提升诊断效率, 我们设计并实现了基于 RAG 的智能运维系统, 整合设备日志、维修手册、历史工单等非结构化数据, 帮助一线人员对故障进行快速诊断支持自然语言问答。

技术栈: LangChain, BGE-m3, BGE-Reranker, Milvus, Elasticsearch, MongoDB, Flask, Docker

核心职责:

1, 多源异构数据处理与结构化 (约 2000 万 token)

使用 pdfplumber 精准提取文本与表格, 保留上下文结构; 设计父子分块策略: 父块为章节标题, 子块为内容段落, 提升检索召回率; 对 8000+ 文档进行清洗、去重、标准化, 最终生成 12 万 chunks

成果: chunk 相关性人工评估达 93.5%, 优于纯递归切分80.8%

2, 分层知识库构建与多级索引设计

构建三级索引体系: 设备类型->部件->故障类型, 元数据写入 ES 和 MongoDB; 使用 BGE-m3 生成向量, 存入 Milvus; 通过 ES 实现 metadata 过滤, 缩小检索范围; 在 Milvus 检索后, 使用 BGE-Reranker 对 Top-K 结果重排序

成果: 检索准确率提升 38%, P99 延迟从 1.2s 降至 680ms

3, 混合式意图识别与精准检索

设计向量相似度 + CrossEncoder + 大模型 Prompt 的两阶段意图识别:

第一阶段: 将用户 query 与 5 类意图模板 (故障诊断、数据查询等) 做向量匹配 (BGE-m3), 计算相似度分数。

第二阶段: 把候选意图和 query 一起送入 Cross-Encoder (BGE-Reranker), 计算更精准的匹配分数, 提升准确率。

第三阶段: 低置信度时调用 Qwen3-14B 进行零样本判断

实现 F1-score 92.3%, 减少 70% 大模型调用成本

支持设备型号、时间范围等结构化字段提取, 结合 ES 过滤, 提升检索精准度

4, 端到端系统评估与性能优化

使用 Ragas 工具评估: 答案相关性 0.88, 上下文精度 0.85;人工评估 1000 条测试集, 准确率达 91.1%;采用 vLLM + PagedAttention 实现批处理, QPS 提升 4.2 倍;引入 LoRA 微调 Qwen3-14B, 在故障诊断任务上准确率 +15%

部署: Flask + Docker 容器化部署, 支持灰度发布

项目成果:

上线后故障平均定位时间从 4.2 小时 -> 1.1 小时。停机时间下降 31.1%;新员工培训成本降低 40%, 通过系统自动生成操作指引支持 15 类设备、200+ 部件的智能问答, 日均调用量 1200+

化工危险品知识图谱搭建

2023.11 - 2024.04

项目描述:

化工危险品根据其物质特性可以大致分为九类, 每一类都需要不同的存放条件和操作流程。为了将这些繁杂的知识整合起来, 帮助工作人员规范操作, 本项目开发了一套化工危险品的知识图谱

技术栈: python,pytorch,bert-bilstm,Robert-large,neo4j

项目职责:

- 1, 参与文本数据的清洗和标准化工作, 通过python中的re模块实现对无关噪声的剔除
- 2, 使用casrel模型实现join方式的实体和关系抽取的方法, 模型对实体识别和spo的f1值分别为78.17%和61.89%
- 3, 使用Robert-large模型代替训练使用的Robert模型, 提高模型对复杂语义的解析能力
- 4, 增加bilstm层, 增强模型对实体边界的识别精度
- 5, 更改bert的输出和主实体的拼接方式, 增强主实体的表达, 使模型F1 值提高到了85.45%和73.12%。
- 6、利用Neo4j等图数据库进行知识存储与管理, 并使用Python将抽取到实体、关系以及属性导入到Neo4j数据库中。

最终成果

通过我们的模型优化, 最终使得查询的准确率提高至94%, 所需要的时间缩短了70%

设备故障诊断系统

2022.09 - 2023.09

项目背景:

针对化工设备传统维修模式导致的维护成本高, 停机损失大, 安全事故率高等痛点, 开发的智能故障诊断与维护优化系统。通过实时采集运行数据, 融合传感器信号与设备运维日志分析, 实现对故障的精准诊断

项目职责:

- 1, 采集8套设备中10类数据及3类环境数据
- 2. 用 TF-IDF 处理运维日志, 特征扩至 156 维, 搭建随机森林基线模型, 准确率 81.72%;
- 3. 迭代 FastText (准确率 92.38%) 与 BERT 模型 (94.15%), 实现早期故障提前 5 天预警;
- 4. 量化 + 知识蒸馏轻量化模型, 体积缩至 92MB, 推理 0.18s, 部署边缘设备。

项目成果:

最终将设备非计划停机时间缩短 45%, 年度维护成本降低 32%, 生产效率提升 18%。

自我评价

- 1, 注重团队合作与沟通, 能高效完成任务并积极分享经验, 具备责任心和执行力。
- 2, 对大模型、RAG、多 Agent 架构等前沿技术保持持续学习热情, 并善于结合业务场景应用。
- 3, 性格沉稳, 遇到问题冷静分析并主动解决。
- 4, 业余时间喜欢阅读文章和研究开源项目, 也会打羽毛球、旅行来保持良好的心态与精力。