

王金鹏

18630848350 | 1254968962@qq.com | 男 | 35岁

工作经验：12年 | 求职意向：大模型算法 | 期望城市：北京



个人优势

- 熟悉机器学习线性回归、逻辑回归、随机森林，深度学习RNN、LSTM、Transformer等基础算法，自然语言处理等相关理论和技术。
- 具备扎实的编程能力，熟练掌握Python编程语言，三年以上机器学习算法相关经验，熟悉PyTorch等主流机器学习框架。在数据预处理、监督学习、迁移学习等有丰富的实战经验。精通Python生态中的各种库numpy, pandas, matplotlib, seaborn等。
- 熟悉AIGC前沿技术，包括大模型底层原理、Prompt设计、ollama框架等大模型应用层相关技术。
- 熟悉大模型相关技术，sft、p-tuning v2、微调训练、RAG技术等。
- 掌握常见开源大语言模型deepseek R1、qwen、glm等。
- 优秀的分析问题、解决问题能力和团队合作意识。

工作经历

马上消费金融股份有限公司 ai研发工程师 2025.06-2025.09

- 设计和优化提示词
 - 负责设计和优化AI模型的提示词，提升模型输出质量、准确性和效率，确保模型在实际应用中的表现符合预期。
- 上下文工程与数据处理
 - 构建和管理AI模型的上下文工程，处理和整合多源数据，确保模型输入数据的准确性和完整性，提升模型的推理能力。
- Agent画布搭建与配置
 - 负责AI Agent的画布搭建和配置，设计模型的交互流程，确保模型能够高效、稳定地运行在实际应用场景中。
- 模型调优与性能优化
 - 持续优化AI模型的性能，包括推理速度、资源消耗和输出质量，确保模型在高负载下的稳定性和可靠性。
- 技术调研与创新
 - 关注AI领域的最新技术动态，参与新技术的调研和选型，探索如何将前沿技术应用到实际项目中，推动产品创新。

海川泽达教育咨询有限公司 nlp算法工程师 2022.07-2025.05

工作描述

- 负责NLP项目的算法研究与开发，包括文本预处理、特征提取、模型构建与优化等。
- 根据项目需求，设计并实现合适的NLP模型，提高模型性能和泛化能力。
- 参与项目方案的讨论和制定，为项目进度和目标提供技术保障。
- 与团队成员密切合作，确保项目顺利进行，并对项目成果进行总结和汇报。
- 关注业界动态，持续学习新知识和技能，为项目创新提供支持。

- 负责大学物理、计算机及相关领域教材的策划、组稿和编辑工作，确保内容科学准确、符合教学需求。
- 与高校教师、专家学者合作，开发高质量、创新性的教材和教学资源。
- 对书稿进行审校、润色和优化，提升内容的可读性和教学适用性。
- 定期走访高校，与物理系、计算机系教师及教学负责人建立长期合作关系，推广出版社教材。
- 组织或参与高校教材研讨会、教师培训会等活动，提升出版社品牌影响力。
- 收集教师和学生的反馈意见，为教材修订和新书开发提供依据。

项目经历

agent项目开发

算法工程师

2025.06-2025.09

在这段时间，我主要完成了4个agent项目的开发搭建：

1 代码AI助手

本项目旨在开发一个代码AI助手，通过提示词设计和上下文工程，为开发人员提供代码建议、错误检测、代码优化等服务，减少开发人员的编码时间，提高代码的可读性和可维护性。

2 会话洞察意图识别改造方案设计

通过搭建agent画布，设计、优化提示词，对用户的输入进行意图识别。通过全局变量标签的筛选，精确的对用户的意图分类，再分别传给下一级的6个子agent，近一步完成对用户对话的深层分析。

3 溯源项目

主要实现的功能：通过提示词的设计、模型的选择，能够对大模型生成的内容进行自动文献标注，增强生成内容的可信度。在生成的每句话结尾自动标注检索的文献和具体片段，并为其生成序号。

4 AgentFlow6.3-prompt工程-prompt创建使用体验优化

通过agent搭建与算法模型的选择,自动将用户输入的原始指令转换为逻辑清晰、结构标准、描述精准的Prompt，以完成对用户提示词的优化，从而更好的帮用户完成他们的任务需求。

基于 Ollama、Docker 和 Dify 的 RAG 智能对话系统

开发工程师

2025.01-2025.05

项目概述：

本项目旨在构建一个基于 Retrieval-Augmented Generation (RAG) 技术的智能对话系统，利用 Ollama 部署 DeepSeek-r1大模型，并结合 Docker 容器化技术和 Dify 平台，实现一个高效、可扩展且易于维护的对话系统。

项目职责：设计基于 RAG 的智能对话系统架构，包括数据预处理、模型推理、对话管理、知识库构建等模块。

Ollama 部署: 使用 Ollama 部署 DeepSeek-v3大模型，并进行模型优化和性能调优。

Docker 容器化: 将系统各个模块容器化，实现环境隔离和便捷部署。

Dify 平台集成: 将系统集成到 Dify 平台，提供用户友好的界面和 API 接口。

数据处理:负责数据收集、清洗、分块、向量化和存储，构建高质量的知识库。

利用公开数据，结合领域文档和用户历史对话数据，形成多源知识库。

利用 LangChain 和 Sentence Transformers 实现文本分块和向量化。

RAG 实现: 结合向量数据库进行知识检索和增强生成。

系统测试和优化: 对系统全面的测试和优化, 确保系统的稳定性、性能和用户体验。

项目总结: 深入理解了 RAG 技术原理和应用场景。

掌握了数据处理全流程, 包括数据收集、清洗、分块、向量化和存储。

熟练使用 Ollama、Docker、Dify 等工具。

提升了系统架构设计、模型部署和优化等方面的能力。

基于大模型qwen2.5智能客服人机对话系统

nlp工程师

2023.06-2024.12

在这个项目中, 主要负责设计和开发一套基于自然语言处理技术的智能客服人机对话系统。该系统旨在为用户提供24/7的即时服务, 解答用户疑问, 提高客户满意度, 并减轻人工客服的压力。

项目架构: BiLSTM、CRF、Bert, Qwen 7B模型、Unit智能机器人、Flask web 服务框架、Redis数据库、Gunicorn服务组件、Supervisor 服务监控器、Neo4j图数据库

主要职责:

1、数据收集与预处理:

收集并整理了超过10万条的客服对话数据, 进行数据清洗, 包括去除无效对话、修正错误文本等。
完成了数据标注工作, 为意图识别和实体抽取提供了训练数据。

2、模型开发与训练:

开发了基于BERT的意图识别模型, 准确率达到91%以上。
利用BiLSTM网络实现了实体抽取功能, F1分数达到90%。

3、模型评估、参数调优和模型优化:

使用验证集评估模型性能, 调整超参数。使用各种评估指标, 如准确率、召回率、F1分数等。

应用L1/L2正则化、Dropout等技术防止过拟合, 添加或改进特征, 以提高模型的表现。

高考专业智能分类

nlp工程师

2022.07-2023.05

项目描述

项目背景:该项目旨在通过对海量文本进行分析挖掘, 实现报考专业的精细化分类和个性化推荐。

1 数据的收集与预处理

数据清洗：去除文本中的噪声数据（如HTML标签、特殊符号等），处理缺失值和异常值。

数据标注：对文本进行人工或半自动标注，构建分类标签体系（如“电子产品”、“服装”、“食品”等）。

数据增强：通过同义词替换、句子重组等方式扩充训练数据，提升模型的泛化能力。

2 文本的特征提取

词嵌入（Word Embedding）：使用预训练的词向量模型（如Word2Vec、GloVe、FastText）将词语转化为低维稠密向量，捕捉词语之间的语义关系。

上下文词嵌入：使用BERT等预训练语言模型，获取词语在上下文中的动态表示，提升文本理解的准确性。

3 模型选择

在项目中分别使用了3种算法：

①随机森林算法:在项目中，采用随机森林算法对文本进行分类。通过构建多个决策树，结合特征重要性排序优化模型性能。在评估数据集上，实现了85%的准确率。

②FastText算法:为提高分类的准确性，引入FastText算法进行文本向量化。通过词向量和领域知识图谱，增强模型对文本特征的代表能力，最终实现89%的准确率。

③bert模型:在项目中，采用bert模型进行文本分类和推荐。通过预训练大量文本数据，学习文本的语义和上下文信息。在验证集上，取得了92.3%的准确率。

4 模型训练与优化

使用交叉熵损失函数，使用Adam、SGD等优化算法进行模型训练，结合学习率衰减策略提升模型收敛速度。使用网格搜索（Grid Search）或贝叶斯优化（Bayesian Optimization）对模型超参数（如学习率、批量大小、网络层数等）进行调优。通过L2正则化、Dropout等技术防止模型过拟合。

5 模型评估

使用准确率（Accuracy）、精确率（Precision）、召回率（Recall）、F1分数等指标评估分类模型的性能。

教育经历

电子科技大学	本科	应用物理学	2009-2013
--------	----	-------	-----------